Curs 1: Incadrare, bibliografie, proces, limbajul Python

Bibliografie

- 1. Jake VanderPlas, <u>Python Data Science Handbook Essential tools for working with data</u> (https://jakevdp.github.io/PythonDataScienceHandbook/), O'Reilly Media Inc., 2017; notebooks (https://github.com/jakevdp/PythonDataScienceHandbook)
- 2. Ron Zacharski, <u>A Programmer's Guide to Data Mining: The Ancient Art of the Numerati</u> (http://quidetodatamining.com/)
- Carl Shan, William Chen, Henry Wang, Max Song, <u>The Data Science Handbook: Advice and Insights</u> from 25 Amazing <u>Data Scientists</u> (http://www.thedatasciencehandbook.com/), Data Science Bookshelf, 2015
- 4. Allen B. Downey, <u>Think Python: How to Think Like a Computer Scientist</u> (http://greenteapress.com/wp/think-python-2e/), editia a doua, Green Tea Press
- 5. Shai Shalev-Shwartz, Shai Ben-David, <u>Understanding Machine Learning: From Theory to Algorithms</u> (http://www.cs.huji.ac.il/~shais/UnderstandingMachineLearning/), Cambridge University Press, 2014
- 6. Kevin Markham, <u>Introduction to machine learning in Python with scikit-learn (video series)</u> (www.dataschool.io/machine-learning-with-scikit-learn/)

Ce este Data Science?

- cunoscuta si ca de data-driven science; un termen generic, referind practici, algoritmi, modalitati de studiu ale problemelor ce implica date
- domeniu interdisciplinar prin care se vizeaza extragerea de cunostinte sau informatii din date aflate in diverse forme
- utilizeaza: matematica, statistica, teoria informatiei, sisteme instruibile (invatare automata, machine learning), vizualizare, ...
- scop: sa se obtina din date cunostinte pe baza carora se poate actiona

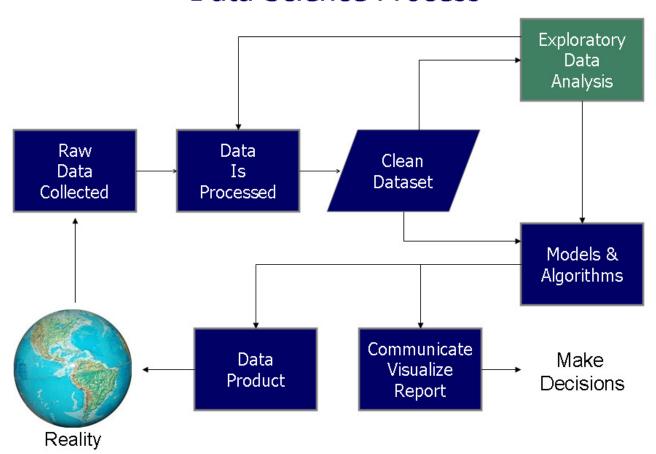
Conferinte si jurnale dedicate:

- <u>European Conference on Data Analysis (ECDA) (http://groups.uni-paderborn.de/eim-i-fg-huellermeier/ecda2018/)</u>
- IEEE International Conference on Data Science and Advanced Analytics (https://dsaa2018.isi.it/home)
- Conference on Statistical Learning and Data Science / Nonparametric Statistics (https://publish.illinois.edu/sldsc2018/)
- International Journal on Data Science and Analytics
 (https://www.springerprofessional.de/en/international-journal-of-data-science-and-analytics/11854902)

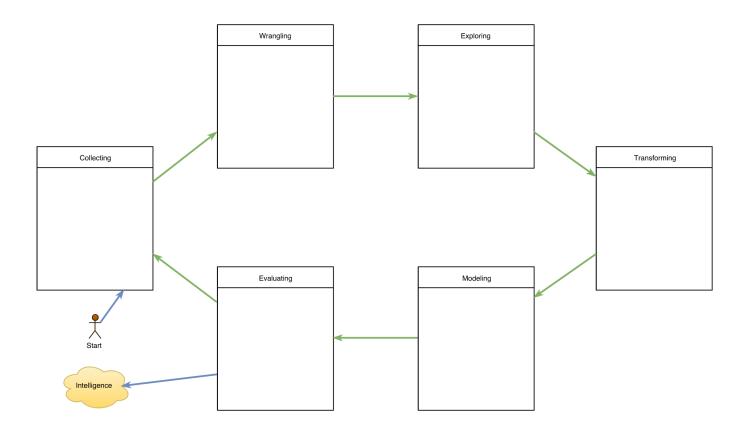
Procesul Data Science

Sursa: Farcaster at English Wikipedia, CC BY-SA 3.0, https://commons.wikimedia.org/w/index.php?curid=40129394)

Data Science Process



Sursa: https://github.com/authman/DAT210x/blob/master/Module1/Course%20Map.pdf (https://github.com/authman/DAT210x/blob/master/Module1/Course%20Map.pdf)

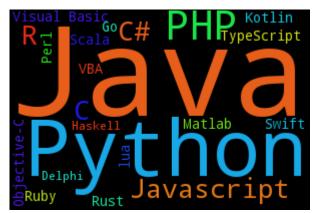


Exemple de probleme tratate de data science

- 1. Google pagerank
- 2. Recomandari de carti pe Amazon: alti cumparatori care au achizitiont cartea X de asemenea au mai fost interesati/au cumparat ...; similar, Netflix prize
- 3. Clasificarea de documente de tip text e.g. mail spam/nonspam
- 4. Campanii politice (Obdama/Binden): gaseste oamenii indecisi
- 5. Reclama targetata: <u>Nissan Motors (https://www.warc.com/NewsAndOpinion/News/36902?)</u>
 Determinarea perferintelor pe modele in functie de regiune
- Domeniul medical: echipament medical de monitorizare (portabil sau nu); imbunatatirea acuratetie diagnosticului; scaderea numarului de re-internari clinice (sursa: https://www.altexsoft.com/blog/datascience/7-ways-data-science-is-reshaping-healthcare/)
- 7. Online customer support (chat bots)
- 8. Detectarea de fraude
- 9. Securitatea datelor, <u>detectare automata de malware (https://www.kaspersky.com/about/press-releases/2014_kaspersky-lab-is-detecting-325000-new-malicious-files-every-day)</u>
- 10. Procesarea de limbaj natural: detectarea sentimentelor din comunicari (tweets, blogs)

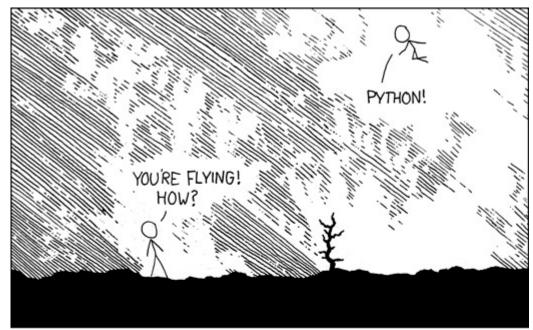
Limbajul Python

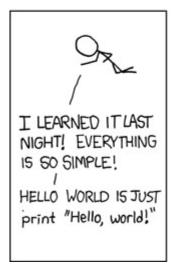
- · Limbaj open source, gratuit
- In februarie 2018: al patrulea limbaj ca popularitate in <u>TIOBE Index (https://www.tiobe.com/tiobe-index/)</u>, dupa Java, C, C++, devansand C#, JavaScript, R
- In aceeasi luna, indexul <u>PYPL (http://pypl.github.io/PYPL.html)</u> raporteaza Python pe locul al doilea, dupa Java



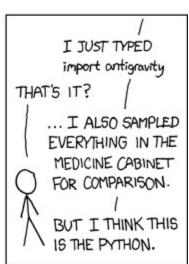
(Sursa: http://pypl.github.io/PYPL.html (http://pypl.github.io/PYPL.html), Februarie 2018)

- In 2017, <u>cel mai popular limbaj pentru Data Science (https://www.kdnuggets.com/2017/01/most-popular-language-machine-learning-data-science.html)</u>, urmat de Java si R.
- Doua versiuni majore: Python 2 (ultima versiune: 2.7) si 3 (versiunea curenta: 3.6).
- Python 2 are mai multe biblioteci dezvoltate, dar ele sunt treptat extinse pentru versiunea 3; diferentele de limbaj intre 2 si 3 sunt totusi mici
- Se recomanda folosirea versiunii 3 a limbajului
- Se poate instala manual sau folosind o distributie de tipul <u>Anaconda (https://conda.io/docs/user-guide/install/download.html)</u>
 - A se vedea despre distributiile Anaconda, Miniconda, Anaconda Enterprise
 - Exista <u>o lista consistenta de distributii (https://wiki.python.org/moin/PythonDistributions)</u> de Python
- · Python este limbaj interpretat si netipizat
- Permite programare imperativa, orientata pe obiect, <u>functionala</u> (<u>https://docs.python.org/3/library/functional.html</u>)
- Exista o paleta larga de biblioteci deja implementate pentru Python, usurand considerabil dezvoltarea de prototipuri sau chiar de aplicatii comerciale larg raspandite.









(Sursa: https://xkcd.com/353/ (https://xkcd.com/353/))

- Peste 120000 pachete dezvoltate (https://pypi.python.org/pypi)
- Python este destul de mult adoptat pentru proiecte comerciale:
 - Which Internet companies use Python (https://www.quora.com/Which-Internet-companies-use-Python)
 - Who uses Python (https://www.quora.com/Who-uses-Python)

De ce Python?

lata cateva motive solide pentru a utiliza Python, conform <u>The unexpected effectiveness of Python in science (https://lwn.net/Articles/724255/)</u>

- 1. Limbajul vine "cu toate bateriile incluse": multitudinea de biblioteci il face perfect pentru o gama larga de proiecte. Cercetatorii care il folosesc activeaza in astronomie, fizica, bioinformatica, chimie, stiinte cognitive etc. si pentru toate aceste domenii exista biblioteci care simplifica mult dezvoltarea de prototipuri. Prin comparatie, limbaje traditionale precum C/C++/Java/Python vin cu mai putin suport disponibil, iar uneori includerea unui pachet/biblioteci poate fi o experienta consumatoare de timp.
- 2. Capacitatea de interoperare cu alte limbaje este iarasi un plus. Exista punti de comunicare (bridges) care permit apelul de cod Python din alte limbaje sau invers. Desigur, aceasta facilitate se regaseste si in alte limbaje.
- 3. Natura dinamica a limbajului poate fi inteligent speculata: o functie poate sa preia o multitudine de parametri (lista, tuplu, dictionar) si cateva linii de cod functioneaza la fel de bine peste toate acestea.
- 4. Python incurajeaza un stil de lucru experimental, via REPL: poate e nevoie de cateva incercari pentru a ajunge la instructiunile potrivite pentru o anumita functionalitate. Incercarea unei alte instructiuni nu necesita recompilarea sau rerularea codului anterior, ci vine in completare pana cand ajungi la ce doresti sa obtii.

Moduri de utilizare

- 1. Codul poate fi scris intr-un fisier text cu extensia py. Lansarea codului se face cu comanda python nume_script.py
- 2. Se poate folosi interpretorul python sau ipython, in care modul de lucru este REPL: read-evaluate-print-loop. REPL permite o prototipizare rapida si scrierea codului in mod incremental. Interpretorul ipython este o varianta imbunatatita a interpretoruui python.

```
Microsoft Windows [Version 10.0.15063]
(c) 2017 Microsoft Corporation. All rights reserved.

C:\Users\Lucian>ipython
Python 3.6.3 |Anaconda custom (64-bit)| (default, Nov 8 2017, 15:10:56) [MSC v.1900 64 bit (AMD64)]
Type 'copyright', 'credits' or 'license' for more information
IPython 6.1.0 -- An enhanced Interactive Python. Type '?' for help.

In [1]: x = [1, 2, 3]
In [2]: x
Out[2]: [1, 2, 3]
In [3]: x.append(10)
In [4]: print(x)
[1, 2, 3, 10]
In [5]:
```

Mai multe detalii pentru lucrul cu interpretorul ipython se gasesc in resursa bibliografica [1], capitolul 1: debug, magic commands, lucru cu interpretorul de comenzi etc.

3. Jupyter notebook - codul este scris in browser, cu suport pentru completare automata de cod. Fisierele rezultate sunt cu extensia ipynb.

```
In [2]: import numpy as np

x = np.array([[1, 2, 3], [4, 5, 6]])
x.max(ax)

Docstring:
    a.max(axis=None, out=None)

Return the maximum along a given axis.

Refer to `numpy.amax` for full documentation.

See Also
------
numpy.amax : equivalent function
Type: builtin_function_or_method
```

O lista de notebooks se gaseste aici (http://nbviewer.jupyter.org/).

4. Folosind diverse framework-uri (de ex Flask), codul Python poate fi folosit pentru crearea de pagini Web, REST endpoints etc.

Variabile, tipuri de date

Clasica afisare de mesaj "Hello world" se obtine cu functia print():

```
In [1]: print("Hello world!")
#sau: print('Hello world')
Hello world!
```

Pentru Python versiunea 2, afisarea se face folosind instructiunea print:

```
print "Hello world!"
```

se pbserva lipsa parantezelor. In ambele cazuri delimitarea sirurilor de caractere se poate face cu
apostroafe sau ghilimele.

Variabilele nu se declara in prealabil impreuna cu tipul lor - Python este un limbaj slab tipizat. Natura unei variabile se deduce din valoarea care ii este asociata:

```
In [2]: x = 3 #x e variabila de tip intreg
y = "abcd" #y este variabila de tip sir de caractere
#se obisnuieste ca numele compuse ale variabilelor sa fie despartite prin _:
nume_complet = "Popescu Ion"
```

Python este case sensitive: Nume_complet si nume_complet refera variabile diferite. Atribuirea se face folosind semnul egal, asa cum s-a vazut mai sus.

Tipurile concrete ale variabilelor poate fi aflat la rulare:

Variabilelor li se pot da nume incepand cu caracter sau , *continuand cu caractere*, sau cifre. Urmatoarele cuvinte rezervate nu pot fi folosite ca nume de variabile:

and	exec	not
assert	finally	or
break	for	pass
class	from	print
continue	global	raise
def	if	return
del	import	try
elif	in	while
else	is	with
except	lambda	yield
del elif else	import in is	try while with

Tipuri numerice

```
In [4]: height = 1.79
    weight = 78
    body_mass_index = weight / height ** 2 #la numitor este inaltimea la patrat
    print("Indicele de masa corporala este: ", body_mass_index)
```

Indicele de masa corporala este: 24.343809494085704

Pentru tipurile intregi, operatorii utilizabili sunt:

- +
- -
- *
- / (impartire cu rezultat in virgula mobila; de retinut ca in Python 2.7 intepretarea operatorul / este diferita fata de cea din Python 3)
- // (impartire intreaga)
- % (modulo)
- ** (ridicare la putere)

```
In [5]: print(7/3)
    print(7/3)
    print(7**3)

2.333333333333333
2
1
343
```

Exista si numere intregi lungi (long integer), precizia lor fiind limitata de memoria alocata procesului:

Pentru tipurile in virgula mobila, operatorii sunt cei de mai sus mai putin modulo si impartire intreaga. Daca un operand este in virgula mobila, operatia returneaza valoare in virgula mobila.

```
In [7]: print(5.0-5)
0.0
```

Numerele se pot compara folosind operatorii:

```
<, >, <=, >=== (egalitate), != (diferit)
```

Exista suport nativ pentru numere complexe:

Sunt admise conversii intre tipuri numerice:

```
In [9]: a = 3.997
b = int(a)
print(b)
print(float(b))

3
3.0

In [10]: #Alte exemple: https://www.tutorialspoint.com/python/python_numbers.htm
```

Siruri de caractere

Pentru variabile de tip sir de caractere, exista posibilitatea de a scrie valori care nu necesita secvente escape:

```
In [11]: a = r'adresa \\michel\protect\....' #remarcam prefixul r
print(a)

#the hard way...
a = 'adresa \\\\michel\\protect\\....'
print(a)

#caractere Unicode
a = u"ĂÎÂŞŢ aăîâṣţ" #se remarca prefixul u
print(a)

adresa \\michel\protect\....
adresa \\michel\protect\....
ĂÎÂŞŢ aăîâṣţ
```

..sau stringuri multilinie, folosind delimitare cu trei ghilimele sau trei apostroafe:

Sirurile de caractere se pot concatena cu + si suporta urmatoarele operatii si functii:

```
In [13]: sir = "Ana " + "are " + "mere"
         print(sir)
         Ana are mere
In [14]:
         print('Lungimea sirului: ', len(sir))
         print('Primul element din sir: ', sir[0])
         print('Ultimul element din sir: ', sir[len(sir)-1])
         print("Ultimul element, in stil Python: ", sir[-1])
         print("Penultimul element din sir, in stil Python: ", sir[-2]) #!!!
         Lungimea sirului: 12
         Primul element din sir: A
         Ultimul element din sir: e
         Ultimul element, in stil Python: e
         Penultimul element din sir, in stil Python: r
In [15]: #Conversia unei variabile de tip non-string in string:
         x = 3
         mesaj = "numarul este " + str(x)
         print(mesaj)
         numarul este 3
In [16]:
         #metode si operatii posibile pe obiect string:
         print(sir.lower())
         print('slicing:', sir[4:7])
         print(sir.find('nu are'))
         print(sir.replace('Ana', 'Ion'))
         ana are mere
         slicing: are
         -1
         Ion are mere
In [17]:
         multi ana = 'Ana' * 10
         print(multi_ana)
         AnaAnaAnaAnaAnaAnaAnaAnaAna
In [18]: cuvantul pere este in sir = 'pere' in sir
         print(cuvantul_pere_este_in_sir)
         cuvantul_pere_nu_este_in_sir = 'pere' not in sir
         print(cuvantul_pere_nu_este_in_sir)
         False
```

True

Demna de mentionat este functia eval, care preia un string de caractere si returneaza un obiect rezultat prin evaluare:

Recomandam citirea <u>documentatiei oficiale (https://docs.python.org/3/library/string.html)</u> pentru tipul de date string.

Python contine tipul bool, util pentru reprezentarea valorilor de adevar True si False:

Se pot face conversii de la tipuri numerice la bool si viceversa: valoarea 0 este asociata lui False, orice non-zero lui True. Invers, True se traduce in 1 si False in 0:

Operatorii aplicabili pe valori bool sunt:

```
In [23]: print(True and False)
    print(True or False)
    print(not False)
    #nu exista xor, dar...
    a, b = True, False
    print(a != b)
False
True
True
True
True
```

Liste

In interiorul unei liste se pot pune oricate elemente, nu neaparat de acelasi tip. Elementele se despart prin virgula; capetele listei sunt marcate prin paranteze drepte:

```
In [24]: lista = [10, 20, 30, 40]
    print('Lungimea listei este', len(lista))
    print('Tipul listei este', type(lista))
    #Lista eterogena: string si int
    lista2 = ['Ana', 234]

Lungimea listei este 4
    Tipul listei este <class 'list'>
```

Elementele unei liste se acceseaza pe baza de indici, incepand de la 0 si terminand cu len(lista)-1. Ultimul element se referentia cu indicele '-1':

```
In [25]: lista = [10, 20, 30]
    print('Ultimul element este:', lista[-1])
    print('Penultimul element este:', lista[-2])

Ultimul element este: 30
    Penultimul element este: 20
```

O lista se poate obtine prin repetarea unei constructii de un numar dorit de ori:

```
In [26]: lista = [1, 2, 3] * 5 #efect similar demonstrat anterior pe string 'Ana'
print(lista)
[1, 2, 3, 1, 2, 3, 1, 2, 3, 1, 2, 3]
```

Putem prelua portiuni intregi din lista, nu doar de pe pozitii individuale, folosind 'decuparea' (slicing), sub forma: lista[k:l] Va rezulta o lista formata din elementele lista[k], lista[k+1], ..., lista[l-1] (se remarca marginea din dreapta a sirului: nu e l, ci l-1). Daca se doreste ca ordinea elementelor sa fie inversata, se foloseste lista[l:k:-1]; elementul de indice l va fi inclus in rezultat, elementul de indice k se va omite:

```
In [27]: lista = [1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
    print(lista)
    sliced = lista[3:8]
    print(sliced)
    sliced_reversed = lista[8:3:-1]
    print(sliced_reversed)

[1, 2, 3, 4, 5, 6, 7, 8, 9, 10]
    [4, 5, 6, 7, 8]
    [9, 8, 7, 6, 5]
In [28]: lista = [10, 20, 30, 40]
```

Formele acceptate pentru slicing sunt:

- a[start:end] # items start through end-1
- a[start:] # items start through the rest of the array
- a[:end] # items from the beginning through end-1
- a[:] # a copy of the whole array

In special ultima forma este interesanta: se obtine o clona a listei a. In lipsa acestui mecanism, doua variabile care indica spre aceeasi lista pot duce la acccese concurente nedorite:

```
In [29]: #aliasing
          a = [1, 2, 3]
          b = a
          print('a=', a)
          print('b=', b)
          a[0] *= -1
          print('Dupa modificare via a: b=', b)
          #a si b refera aceeasi zona de memorie
         a = [1, 2, 3]
         b = [1, 2, 3]
         Dupa modificare via a: b= [-1, 2, 3]
In [30]: #copiere de lista
         a = [1, 2, 3]
          b = a[:]
          print('a=', a)
          print('b=', b)
          a[0] *= -1
          print('Dupa modificare: a=', a)
          print('Dupa modificare: b=', b)
          #a si b refera zone de memorie diferite
         a = [1, 2, 3]
         b = [1, 2, 3]
         Dupa modificare: a= [-1, 2, 3]
         Dupa modificare: b= [1, 2, 3]
```

Copierea unei liste se poate face si cu metoda copy:

```
In [31]: #copiere de lista cu metoda copy
a = [1, 2, 3]
b = a.copy()
print('a=', a)
print('b=', b)
a[0] *= -1
print('Dupa modificare: a=', a)
print('Dupa modificare: b=', b)
#a si b refera zone de memorie diferite
a= [1, 2, 3]
b= [1, 2, 3]
Dupa modificare: a= [-1, 2, 3]
Dupa modificare: b= [1, 2, 3]
```

Listele pot fi concatenate:

```
In [32]: a = [1, 2, 3]
b = [10, 20, 30]
c = a+b
print(c)
[1, 2, 3, 10, 20, 30]
```

La o lista se pot adauga elemente:

```
In [33]: a = [1, 2, 3]
a.append(100)
print(a)
[1, 2, 3, 100]
```

Se recomanda ca daca pentru o lista se cunoaste capacitatea maxima sau chiar exacta, sa se prealoce, in loc sa se foloseasca adaugari repetate:

Sortarea unei liste se face cu functia sorted, care optional poate sa preia:

- un parametru numit reverse de tip boolean, care precizeaza daca se face sortare descrescatoare
- un parametru numit key, care face referinta la o functie ce determina politica de sortare

```
In [35]: #Sortare crescatoare
a = [5, 1, 4, 3]
print(sorted(a))

[1, 3, 4, 5]

In [36]: # Sortare descrescatoare
print(sorted(a, reverse=True))

[5, 4, 3, 1]

In [37]: #Sortare cu cheie specificata
siruri = ['ccc', 'aaaa', 'd', 'bb']
print(sorted(siruri, key=len))

['d', 'bb', 'ccc', 'aaaa']
```

Functia sorted returneaza o noua lista, lasand pe cea originara nemodificata. Daca se doreste ca sortarea sa se faca in cadrul liste originare, se va folosi metoda sort a tipului lista. Metoda sort returneaza None.

Stergerea unui element dinstr-o lista, de pe o pozitie (indice) specificat se face cu del:

```
In [39]: lista = [10, 20, 30]
    del lista[1]
    print(lista)
    [10, 30]
```

Testarea existentei unui element intr-o lista se face cu operatorul in:

```
In [40]: lista = ['Ana', 'are', 'mere']
print('portocale' in lista )
False
```

Minimul si maximul unei liste se obtin cu functiile min respectiv max.

Alte metode apartinand tipului list sunt exemplificate mai jos:

```
In [41]: lista = [10, 20, 30, 10]
         #De cate ori apare elementul 10 in lista?
         print('De cate ori apare elementul 10 in lista', lista.count(10))
         #Care e primul index in care un anumit element apare in lista?
         print('Care e primul index in care un anumit element apare in lista?', lista.i
         ndex(20))
         #daca pentru metoda index se specifica un element care nu exista, se arunca er
         oare:
         # print(lista.index(100000))
         #ValueError: 100000 is not in list
         #Inserare elementului 100 pe indexul 2 in lista:
         lista.insert(2, 100)
         print('Inserare elementului 100 pe indexul 2 in lista', lista)
         #Inversarea ordinii elementelor dintr-o lista, in-place
         lista.reverse()
         print('Inversarea ordinii elementelor dintr-o lista, in-place', lista)
         #Stergerea unui element din lista, prima aparitie
         lista.remove(10)
         print('Stergerea unui element din lista, prima aparitie', lista)
         lista.clear()
         print('Lista a fost golita:', lista)
```

De cate ori apare elementul 10 in lista 2

Care e primul index in care un anumit element apare in lista? 1

Inserare elementului 100 pe indexul 2 in lista [10, 20, 100, 30, 10]

Inversarea ordinii elementelor dintr-o lista, in-place [10, 30, 100, 20, 10]

Stergerea unui element din lista, prima aparitie [30, 100, 20, 10]

Lista a fost golita: []

Pentru testarea faptului ca toate elementele (respectiv: macar un element al) unei liste de valori boolene sunt cu valoarea true, se va folosi functia al1 (respectiv: any).

```
In [42]: lista = [True, False, True]
    print('Macar unul e True:', any(lista))
    print('Toate sunt True:', all(lista))

Macar unul e True: True
    Toate sunt True: False
```

Daca lista este goala, functia all returneaza True, iar any - False.

```
In [43]: print('Macar unul e True:',any([]))
print('Toate sunt True:',all([]))

Macar unul e True: False
Toate sunt True: True
```

O metoda deosebit de eleganta de procesare a elementelor unei liste este prin list comprehension, ce se va prezenta in cadrul sectiunii de instructiuni.

Tupluri

In timp ce o lista permite modificarea continutului sau, un tuplu reprezinta o colectie ordonata imuabila. Elementele se separa cu virgula, capetele tuplului se marcheaza de regula cu paranteze rotunde, sau pot lipsi.

```
In [44]: | tuplu1 = ('informatica', 3, 'dimineata')
         tuplu2 = 'chimie', 2, 'seara'
         print(tuplu1)
         ('informatica', 3, 'dimineata')
In [45]:
         print(tuplu1[0])
         informatica
In [46]:
         print(tuplu1[-1])
         dimineata
In [47]: print(len(tuplu1))
         3
In [48]: tuplu gol = ()
         print(len(tuplu_gol))
In [49]: la tuplul cu doar o valoare trebuie adaugata virgula la sfarsit = (42,)
         print(len(la_tuplul_cu_doar_o_valoare_trebuie_adaugata_virgula_la_sfarsit))
         1
```

Elementele unui tuplu pot fi preluate individual in variabile:

```
In [50]: print(tuplu1)
    a, b, c = tuplu1
    print(a)
    print(b)
    print(c)

    ('informatica', 3, 'dimineata')
    informatica
    3
    dimineata

In [51]: #Tuplele se pot concatena
    tuplu1 + tuplu2

Out[51]: ('informatica', 3, 'dimineata', 'chimie', 2, 'seara')
```

```
In [52]: #Convertirea unei liste in tuplu:
    lista = [1, 2, 3, 4, 5]
    tuplu = tuple(lista)
    print(type(tuplu))
    print(tuplu)

    <class 'tuple'>
        (1, 2, 3, 4, 5)
```

Dictionare

Dictionarele sunt colectii de asocieri intre chei si valori. Colectia de tip dictionar se demarcheaza cu acolade. Elementele se acceseaza specificand intre paranteze drepte valoarea cheii.

```
geografie = {} #dictionar gol
In [53]:
         geografie = {'Romania': 'Bucuresti', 'Serbia': 'Belgrad'}
         print('Lungimea este:', len(geografie))
         key = 'Romania'
         print('Valoarea pentru cheia', key, 'este',geografie[key])
         geografie['Grecia'] = 'Atena' #adaugare de pereche cheie-valoare in dictionar
         #daca se foloseste o cheie care exista, valoarea asociata va fi suprascrisa cu
          cea noua
         geografie['Grecia'] = 'Athens'
         #accesarea folosind o cheie invalilda duce la eroare (KeyError)
         # geografie['Franta']
         #pentru a evita eroare la rulare, se poate folosi metoda get; daca cheia nu e
          gasita in dictionar, se returneaza None
         print(geografie.get('Franta'))
         #daca se doreste returnarea ueni valori prestabilite in cazul lipsei cheii, me
         toda get accepta un parametru suplimentar
         print(geografie.get('Franta', '<Nu exista in dictionar>'))
         Lungimea este: 2
         Valoarea pentru cheia Romania este Bucuresti
         None
         <Nu exista in dictionar>
```

Listele cheilor unui dictionar se determina cu metoda keys, respectiv values:

```
In [54]: print('Chei:', geografie.keys())
    print('Valori:', geografie.values())

Chei: dict_keys(['Romania', 'Serbia', 'Grecia'])
    Valori: dict_values(['Bucuresti', 'Belgrad', 'Athens'])
```

Oricare din colectii poate fi transformata intr-o lista prin apelul constructorului list() care poate prelua o colectie oarecare:

```
In [55]: print(list(geografie.keys()))
    print(list(geografie.values()))

['Romania', 'Serbia', 'Grecia']
    ['Bucuresti', 'Belgrad', 'Athens']
```

Stergerea unei chei din dictionar, impreuna cu valoarea asociata, se face cu instructiunea del:

```
In [56]: del geografie['Grecia']
    print(geografie)

{'Romania': 'Bucuresti', 'Serbia': 'Belgrad'}
```

Testarea faptului ca o anumita cheie se afla intr-un dictionar se face cu operatorul in:

```
In [57]: print('Grecia' in geografie)
False
```

Golirea unui dictionar se face, precum la alte tipuri colectie cu metoda clear:

```
In [58]: # geografie.clear()
```

Colectia perechilor (cheie, valoare) a unui dictionar se obtine cu metoda items():

```
In [59]: print(geografie.items())
    print(list(geografie.items()))

    dict_items([('Romania', 'Bucuresti'), ('Serbia', 'Belgrad')])
    [('Romania', 'Bucuresti'), ('Serbia', 'Belgrad')]
```

Daca la un dictionar se doreste adaugarea perechilor (cheie-valoare) ale altui dictionar se foloseste metoda update:

```
In [60]: geografie_asia = {'China':'Beijing', 'India':'New Delhi'}
geografie.update(geografie_asia)
print(geografie)

{'Romania': 'Bucuresti', 'Serbia': 'Belgrad', 'China': 'Beijing', 'India': 'N
ew Delhi'}
```

Clonarea unui dictionar se face cu metoda copy:

```
In [61]: geografie_copie = geografie.copy()
    geografie_copie['India'] = 'New----Delhi'
    print(geografie['India'], ',', geografie_copie['India'])
    New Delhi , New----Delhi
```

Alte colectii

Se foloseste foarte frecvent functia range care produce o secventa de numere. Formele de utilizare sunt:

- range(n) produce colectia 0, 1, ..., n-1
- range(start, stop) produce colectia start, start+1, ..., stop-1
- range(start, stop, step) produce secventa in functie de semnul lui step:
 - start, start+step, start+2*step, ... k, unde k este cel mai mare intreg mai mic decat stop, care se obtine prin adaugarea unui multiplu intreg al pasului step la start
 - start, start+step, start+2*step,k unde k este cel mai mare intreg mai mare decat stop, obtinut prin adaugarea unui multiplu intreg al pasului step la start

Functia enumerate porneste de la o colectie si da acces simultan atat la indicele elementului din colectie, cat si la elementul curent:

Functia zip permite 'imperecherea' a doua liste

Instructiuni, comentarii

Blocuri de instructiuni

Instructiunile se scriu de regula cate una pe linie. Daca pentru o instructiune prea lunga se doreset continuarea ei pe linia urmatoare, se pune la finalul liniei caracterul \ si se continua pe rand nou:

Pentru colectii, continuarea pe rand nou nu necesita caracter backslash:

Se pot scrie mai multe instructiuni pe o linie, despartindu-se cu caracterul ';'. Acest stil insa e nerecomandat

Un bloc de instructiuni va folosi aceeasi indentare. Se poate folosi orice pentru indentare (tab, sau acelasi numar de spatii), dar stilul de indentare trebuie sa fie unitar. Un astfel de bloc de instructiuni se termina cu prima linie care nu e indentata in acelasi stil ca si blocul.

Linia aceasta nu face parte din blocul corespunzator instructiunii if

Comentarii

Comentariile sunt fie pe o singura linie, incepand de la caracterul # pana la finalul liniei, fie folosind apostroafe sau ghilimele, de trei ori la inceput si la sfarsit de comentariu:

```
In [71]: """Comentariu
foarte lung"""
Out[71]: 'Comentariu\nfoarte lung'
```

Atribuirea

Atribuirea a fost exemplificata mai sus. Mai avem variantele:

```
In [72]: #Atribuire multipla cu o valoare
    a = b = c = 3
In [73]: #Atribuire multipla cu mai multe valori simultan
    a, b = 2, 3
    print(a, b)
    2 3
```

Ultima forma poate fi speculata astfel: daca a si b sunt doua variabile si se doreste interschimbarea valorilor lor, atunci putem scrie:

```
In [74]: print('Inainte de interschimbare: ', a, b)
a, b = b, a
print('Dupa interschimbare: ', a, b)

Inainte de interschimbare: 2 3
Dupa interschimbare: 3 2
```

Instructiunea if

Formele uzuale sunt:

```
if expresie:
    bloc 1
else
    bloc 2
```

Partea else poate sa lipseasca. Blocurile de instructiuni ce urmeaza dupa if si else sunt indentate.

```
In [75]: var1 = 100
var2 = 200
if var1 > var2:
    print("In if - Got a true expression value")
    print(var1)
else:
    print("In else - Got a false expression value")
    print(var2)
In else - Got a false expression value
200
```

O instructiune if poate conine multiple teste, folosind elif:

```
if expression1:
    statement(s)
elif expression2:
    statement(s)
elif expression3:
    statement(s)
else:
    statement(s)
```

Se evalueaza in ordine conditiile epxression1, epxression2 etc. pana la prima care e gasita ac fiind adevarata; blocul ei este executat si restul se ignora

```
In [76]: var = 100
   if var == 200:
        print("1 - Got a true expression value")
        print(var)
   elif var == 150:
        print("2 - Got a true expression value")
        print(var)
   elif var == 100:
        print("3 - Got a true expression value")
        print(var)
   else:
        print("4 - Got a false expression value")
        print(var)

3 - Got a true expression value
100
```

Instructiunea if se poate folosi si inline, in forma:

```
expression_if_true if condition else expression_if_false
```

Exemplu:

```
In [77]: CNP = '5678901234567'
  gen_masculin = True if int(CNP[0]) % 2 == 1 else False
  print('gen masculin:', gen_masculin)

gen masculin: True
```

Ciclare: for

Ciclarea cu for este folosita pentru a itera o instructiune sau un bloc de instructiuni peste o colectie cunoscuta.

```
In [78]: for i in range(0, 3):
             print('i=', i)
         i = 0
         i=1
         i=2
In [79]:
         #Exemplu: calculul factorialului unui numar
         n = 100
         p = 1
         for i in range(1, n+1):
             p *= i
         print(n, '!=', p)
         100 != 9332621544394415268169923885626670049071596826438162146859296389521759
         9993229915608941463976156518286253697920827223758251185210916864000000000000
         0000000000
In [80]: # %%timeit
         # n = 100
         # list_numbers = [str(i) for i in range(1, n+1)]
         # expression = '*'.join(list_numbers)
         # print(eval(expression))
In [81]: | lista_nume = ['Ana', 'Dan', 'Rares', 'Dana']
         for nume in lista nume:
             print(nume)
         Ana
         Dan
         Rares
         Dana
In [82]:
         geografie = {'Romania': 'Bucuresti', 'Serbia': 'Belgrad', 'Grecia':'Atena'}
         for key in geografie:
             print(geografie[key])
         Bucuresti
         Belgrad
         Atena
```

```
In [83]: #iterare cu doua elemente, peste colectie de perechi
         for key, value in geografie.items():
             print('Capitala pentru', key, 'este', value)
         Capitala pentru Romania este Bucuresti
         Capitala pentru Serbia este Belgrad
         Capitala pentru Grecia este Atena
In [84]: for index, element in enumerate(lista_nume):
             print(index, element)
         0 Ana
         1 Dan
         2 Rares
         3 Dana
In [85]:
         #enumerare peste doua colectii 'impreunate'
         lista_ani = [20, 21, 22, 23]
         for nume, ani in zip(lista_nume, lista_ani):
             print(nume, 'are', ani, 'ani')
         Ana are 20 ani
         Dan are 21 ani
         Rares are 22 ani
         Dana are 23 ani
```

Se poate forta iesirea dintr-un ciclu for cu instructiunea break. Se poate sari peste o parte din blocul unui ciclu for si trece la ciclarea urmatoare folosind continue:

```
In [86]: for i in range(100):
              if i > 5:
                  break
              print(i)
          0
          1
          2
          3
          4
In [87]: for i in range(10):
              if i % 2 == 0:
                  continue
              print(i)
          1
          3
          5
          7
          9
```

O forma aparte a instructiunii for in Python este aceea in care la final se pune else: daca nu s-a executat 'break' in corpul ciclului, atunci se executa blocul de dupa else:

```
In [88]: for n in range(2, 10):
    for x in range(2, n):
        if n % x == 0:
            print( n, 'equals', x, '*', n//x)
            break
    else:
        # loop fell through without finding a factor
        print(n, 'is a prime number')

2 is a prime number
3 is a prime number
4 equals 2 * 2
5 is a prime number
6 equals 2 * 3
7 is a prime number
8 equals 2 * 4
9 equals 3 * 3
```

Ciclare: while

Folosind while se cilceaza peste un bloc de instructiuni atata timp cat o anumita conditie este adevarata:

```
while test_expression:
  body of while
```

```
In [89]: n = 10

# initialize sum and counter
my_sum = 0
i = 1

while i <= n:
    my_sum = my_sum + i
    i = i+1  # update counter

# print the sum
print("The sum is", my_sum)</pre>
```

The sum is 55

Se poate ca o instructiune while sa se termine cu else, al carei bloc se executa cand expresia de test devine falsa, dar numai daca nu s-a ajuns la un break.

Collection comprehension

Pornind de la o colectie (cel mai frecvent caz: de la o lista) se poate crea o alta lista, folosind *list comprehension* - in esenta o ciclare:

```
In [90]: lista_numere = [1, 3, 6, 21, 22, 32, 33]
lista_patrate = [i*i for i in lista_numere]
print(lista_patrate)
[1, 9, 36, 441, 484, 1024, 1089]
```

Optional, la fiecare pas al iterarii se poate lua in considerare o conditie if inline:

```
In [91]: lista_patrate_doar_numere_pare = [i*i for i in lista_numere if i % 2 == 0]
    print(lista_patrate_doar_numere_pare)
    [36, 484, 1024]
```

... sau se foloseste si else pe langa if:

```
In [92]: lista_patrate_sau_cuburi = [i**2 if i % 2 == 0 else i ** 3 for i in lista_nume
    re]
    print(lista_patrate_sau_cuburi)
[1, 27, 36, 9261, 484, 1024, 35937]
```

Exercitiu: daca o lista are ca elemente alte liste, cum se poate determina lista 'flattened'? De exemplu, pentru lista I = [[1, 2], [3, 4, 5], [10]] se doreste rezultatul I2 = [1, 2, 3, 4, 5, 10]

Comprehension se poate folosi si peste alte tipuri de colectii: de exemplu, putem pleca de la o lista si producem dictionar:

```
In [94]: lista_numere = [1, 3, 6, 21, 22, 32, 33]
    dictionar_numere_si_patrate = {i:i**2 for i in lista_numere}
    print(dictionar_numere_si_patrate)

{1: 1, 3: 9, 6: 36, 21: 441, 22: 484, 32: 1024, 33: 1089}
```

...sau liste de tuple:

```
In [95]: colours = [ "red", "green", "yellow", "blue" ]
    things = [ "house", "car", "tree" ]
    produs_cartezian = [(colour, thing) for colour in colours for thing in things]
    print(produs_cartezian)
    assert len(produs_cartezian) == len(colours) * len(things)

[('red', 'house'), ('red', 'car'), ('red', 'tree'), ('green', 'house'), ('green', 'car'), ('green', 'car'), ('yellow', 'house'), ('yellow', 'car'), ('yellow', 'tree')]
```

Mai jos sunt cateva exemple de utilizare de comprehension peste colectii.

```
In [96]: #Conversie de temperaturi din Celsius in Fahrenheit: valoarea in Fahrenheit se
  obtine cu formula: 1.8 * gradeCelsius + 32
  gradeCelsius = [-20, -10, 0, 5, 23, 35]
  gradeFahrenheit = [1.8*gc + 32 for gc in gradeCelsius]
  print(gradeFahrenheit)
```

```
[-4.0, 14.0, 32.0, 41.0, 73.4, 95.0]
```

```
In [97]: #Suma patratelor numerelor de la 1 la 20
print(sum([x**2 for x in range(21)]))
```

2870

In [98]:

#Dintr-o lista de cuvinte se mentin doar cele care nu fac parte dintr-o altali sta specificata (stop words) stop_words = ["a", "about", "above", "across", "after", "afterwards", "again", "against", "all", "almost", "alone", "along", "already", "also", "alt hough", "always", "am", "among", "amongst", "amoungst", "amount", "an", "and", "another", "any","anyhow","anyone","anything","anyway", "anywhere", "are", "ar ound", "as", "at", "back", "be", "became", "because", "become", "becomes", "become ing", "been", "before", "beforehand", "behind", "being", "below", "beside", "b esides", "between", "beyond", "bill", "both", "bottom", "but", "by", "call", "can", "cannot", "cant", "co", "con", "could", "couldnt", "cry", "de", "describe", "detail", "do", "done", "down", "due", "during", "each", "eg", "eight", "e ither", "eleven", "else", "elsewhere", "empty", "enough", "etc", "even", "ever" , "every", "everyone", "everything", "everywhere", "except", "few", "fifteen", "fify", "fill", "find", "fire", "first", "five", "for", "former", "formerly" "forty", "found", "four", "from", "front", "full", "further", "get", "give", "go", "had", "has", "hasnt", "have", "he", "hence", "here", "hereafter", "hereby", "herein", "hereupon", "hers", "herself", "him", "himself", "his", "how", "however", "hundred", "ie", "if", "in", "inc", "indeed", "interest", "into", "is", "it", "its", "itself", "keep", "last", "latter", "latterly", "least", "less", "ltd", "made", "many", "may", "me", "meanwhile", "might", "mill", "mine", "more", "moreover", "most", "mostly", "move", "much", "must", "my", "m yself", "name", "namely", "neither", "never", "nevertheless", "next", "nine", "no", "nobody", "none", "noone", "nor", "not", "nothing", "now", "nowhere", "of", "offen", "on", "once", "one", "only", "onto", "or", "other", "other s", "otherwise", "our", "ours", "ourselves", "out", "over", "own", "part", "pe , "perhaps", "please", "put", "rather", "re", "same", "see", "seem", "seeme d", "seeming", "seems", "serious", "several", "she", "should", "show", "side", "since", "sincere", "six", "sixty", "so", "some", "somehow", "someone", "some "sometimes", "somewhere", "still", "such", "system", thing", "sometime", e", "ten", "than", "that", "the", "their", "them", "themselves", "then", "then "there", "thereafter", "thereby", "therefore", "therein", "thereupon", "t hese", "they", "thickv", "thin", "third", "this", "those", "though", "three", "through", "throughout", "thru", "thus", "to", "together", "too", "top", "toward", "towards", "twelve", "twenty", "two", "un", "under", "until", "up", "upo n", "us", "very", "via", "was", "we", "well", "were", "what", "whatever", "whe "whence", "whenever", "where", "whereafter", "whereas", "whereby", "wherei n", "whereupon", "wherever", "whether", "which", "while", "whither", "who", "w hoever", "whole", "whom", "whose", "why", "will", "with", "within", "without", "would", "yet", "you", "your", "yours", "yourself", "yourselves", "the"]
paragraph_list = ['Stopword', 'filtering', 'is', 'a', 'common', 'step', 'in', 'prepro cessing', 'text', 'for', 'various', 'purposes', 'This', 'is', 'a', 'list', 'of', 'severa l','different','stopword','lists','extracted','from','various','search','engin es', 'libraries', 'and', 'articles', 'There', 'is', 'a', 'surprising', 'number', 'of', 'different','lists'] print('Initial:',paragraph list) filtrat = [cuvant for cuvant in paragraph list if cuvant not in stop words] print('\nDupa filtrare:', filtrat)

http://localhost:8888/nbconvert/html/Curs1.ipynb?download=false

```
Initial: ['Stopword', 'filtering', 'is', 'a', 'common', 'step', 'in', 'prepro
cessing', 'text', 'for', 'various', 'purposes', 'This', 'is', 'a', 'list', 'o
f', 'several', 'different', 'stopword', 'lists', 'extracted', 'from', 'variou
s', 'search', 'engines', 'libraries', 'and', 'articles', 'There', 'is', 'a',
'surprising', 'number', 'of', 'different', 'lists']

Dupa filtrare: ['Stopword', 'filtering', 'common', 'step', 'preprocessing',
'text', 'various', 'purposes', 'This', 'list', 'different', 'stopword', 'list
s', 'extracted', 'various', 'search', 'engines', 'libraries', 'articles', 'Th
ere', 'surprising', 'number', 'different', 'lists']
```

Functii

Functiile sunt de trei feluri:

- Functii deja definite in limbajul Python, cum ar fi len(), print()
- Functii definite de utilizator
- Lambda functii

O functie se defineste folosind cuvantul cheie def. Blocul de instructiuni ce defineste corpul functiei este indentat. O functie poate sa nu returneze nimic in mod explicit (si in acest caz rezultatul returnat este considerat None), sau orice numar de parametri.

Functii definite de utilizator

Urmeaza cateva exemple de functii definite de utilizatorcu comentarii:

```
In [99]: def hello():
    print('Salutare')
hello()
```

Salutare

```
In [100]:
          def hello with name(nume):
              Functia preia un argument si afiseaza mesajul: Salutare urmat de valoarea
           argumentului.
              Functia returneaza argumentul cu litere mari.
               :param nume: numele care se cere afisat
              print('Salutare ' + nume)
              return nume.upper()
          nume = 'Natalia'
          nume_litere_mari = hello_with_name(nume)
          print(nume_litere_mari)
          help(hello with name)
          print(hello_with_name.__doc__)
          Salutare Natalia
          NATALIA
          Help on function hello with name in module main :
          hello_with_name(nume)
              Functia preia un argument si afiseaza mesajul: Salutare urmat de valoarea
          argumentului.
              Functia returneaza argumentul cu litere mari.
              :param nume: numele care se cere afisat
              Functia preia un argument si afiseaza mesajul: Salutare urmat de valoarea
          argumentului.
              Functia returneaza argumentul cu litere mari.
              :param nume: numele care se cere afisat
In [101]:
          #exemplu de functie care returneaza mai multe valori simultan
          #rezultatul este un tuplu cu doua valori
          def min max(a, b):
              if a<b:</pre>
                   return a, b
              else:
                   return b, a
          x, y = 20, 10
          min_2, max_2 = min_max(x, y)
          print('Minimul este:', min_2, '; maximul este:', max_2)
          Minimul este: 10; maximul este: 20
In [102]: #parametrii se pot da prin numele lor urmat de egal si valoarea efectiva
          min_max(a=5, b=14)
Out[102]: (5, 14)
In [103]: min_max(b=3, a=20)
Out[103]: (3, 20)
```

Pot exista parametri cu valori implicite, precizati la finalul listei de parametri formali:

```
In [104]: def greet(name, msg = "Good morning!"):
    """
    This function greets to the person with the provided message.

If message is not provided, it defaults to "Good morning!"
    :param name: Name of the guy to be greeted
    :param msg: a message shown as greeting. It defaults to "Good morning"
    """

    print("Hello",name + ', ' + msg)

greet("Kate")
greet("Bruce","How do you do?")
# echivalent: greet(name="Bruce",msg="How do you do?")

Hello Kate, Good morning!
Hello Bruce, How do you do?
```

Putem avea n parametru care sa permita numar variabil de valori trimise la apel; acest tip de parametru se scrie cu * urmata de numele parametrului formal (de exemplu: *args)

```
In [105]: #Functie cu numar arbitrar de argumente
    def greet(*names, msg = "Good morning!"):
        for name in names:
            print('Hello', name + ', ' + msg)
        greet('Dan', 'John', 'Mary')
        greet('Dan', 'John', 'Mary', msg='How do you do?')

Hello Dan, Good morning!
    Hello John, Good morning!
    Hello Mary, Good morning!
    Hello Dan, How do you do?
    Hello John, How do you do?
    Hello Mary, How do you do?
```

Se pot defini functii care sa manipuleze un numar variabil de parametri dati la apel sub forma de nume_parametru=valoare_parametru; denumirea traditionala este kwargs (key-value arguments), numele parametrului se prefixaza cu **:

Acelasi efect se obtine prin despachetarea de dictionare, folosind **:`

```
In [107]: dictionar_argumente = {'fruits':'apples', 'quantity':'3', 'measurement_unit':
    'kg'}
    demo_kwargs(**dictionar_argumente)

{'fruits': 'apples', 'quantity': '3', 'measurement_unit': 'kg'}
```

Ordonarea parametrilor declarati intr-o functie este:

```
    parametri formali preluati prin pozitie
    *args
    parametri cu valori asociate
    **kwargs
```

def example2(arg_1, arg_2, *args, kw_1="shark", kw_2="blobfish", **kwargs):

Lambda functii

Se pot defini functii anonime (sau: lambda functii), continand o expresie, pentru care nu se considera necesara definirea unor functii separate. O lambda functie poate sa preia oricate argumente si calculeaza o expresie pe baza lor. Lambda functiile pot accesa doar parametrii trimisi (nu si pe cei globali). Se va omite cuvantul return, expresia calculata este cea care se returneaza automat.

Functii callback

Numele unei functii reprezinta adresa de memorie a acelei functii:

```
In [111]: def sum_2(x, y):
    return x+y

def dif_2(x, y):
    return x - y

print(sum_2)
print(dif_2)

<function sum_2 at 0x000001FA909169D8>
<function dif_2 at 0x000001FA90916510>
```

Putem folosi acest mecanism pentru a trimite functii ca parametri intr-o alta functie:

```
In [112]: def complex_operation(x, y, to_be_called):
    return to_be_called(x, y)

print(complex_operation(2, 3, sum_2))
print(complex_operation(2, 3, dif_2))

5
-1
```